

Aula 07

Hugo Silva

Introdução

Razão Áurea

Gradiente

Método de
Newton

BFGS

Resumo

Aula 07 - Otimização sem restrições

Hugo Vinícius Leão e Silva

hugovlsilva@gmail.com, hugo.vinicius.16@gmail.com, hugovinicius@ifg.edu.br

Instituto Federal de Educação, Ciência e Tecnologia de Goiás
Campus Anápolis
Curso de Bacharelado em Ciência da Computação

16 de setembro de 2021



Aula 07

Hugo Silva

Introdução

Razão Áurea

Gradiente

Método de
Newton

BFGS

Resumo

1 Introdução

2 Busca pela Razão Áurea



3 Método do Gradiente

4 Método de Newton

5 Broyden-Fletcher-Goldfarb-Shanno – BFGS

6 Resumo


Otimização → buscar mínimos ou máximos de uma função K -dimensional:



Pode ou **não**¹ haver restrições.


¹Aqui trataremos os casos sem restrições. A disciplina **Otimização de Sistemas** tratará o caso com restrições para sistemas lineares.

- Método fechado aplicável a funções **univariadas**;
- Assemelha-se ao Método da Bissecção. Iterativamente se divide o intervalo $[x_l, x_u]$ de forma que contém o mínimo ou o máximo:




- A função precisa ser **unimodal** no intervalo! Como fazer?

- No Método da Bissecção, faz-se um simples teste para verificar se tem uma raiz no intervalo: $f(x_l) \leq f(x_u)$;
- Para buscar extremidades são necessários três pontos: x_l , x_u e x_r . Como calcular x_r ? Usando a Razão Áurea $R = \frac{\sqrt{5}-1}{2} = 0,61803\dots$



- Considerando a maximização², faz-se $d = R \times (x_u - x_l)$, $x_1 = x_l + d$ e $x_2 = x_u - d$:




- Se $f(x_1) > f(x_2)$, então $[x_l, x_2)$ é eliminado e $x_2 = x_l$;
- Se $f(x_2) > f(x_1)$, então $(x_1, x_u]$ é eliminado e $x_u = x_1$.
- A cada iteração, o intervalo é reduzido à taxa de 61,8%.
- O processo continua até que atingir a tolerância

²Na minimização, trocam-se os sinais de desigualdade acima.



- **Exercício numérico** – buscar o máximo de $f(x) = 2 \sin\left(x - \frac{x^2}{10}\right)$ no intervalo $[0, 4]$:



- O gradiente³ $\nabla f(\mathbf{x}) = \left[\frac{\partial f(\mathbf{x})}{\partial x_1} \quad \frac{\partial f(\mathbf{x})}{\partial x_2} \quad \dots \quad \frac{\partial f(\mathbf{x})}{\partial x_M} \right]^T$ define a direção de busca pelo ponto ótimo;
- Também conhecido como *gradient descent* – gradiente descendente – ou *steepest descent*;
- Faz-se uma aproximação/ajuste local de 1º grau da função (interpolação linear)⁴ de $f(\mathbf{x})$;
- Se $f(\mathbf{x})$ cresce mais rapidamente na direção $\nabla f(\mathbf{x})$, então $-\nabla f(\mathbf{x})$ indica a direção de *descida mais rápida* de $f(\mathbf{x})$, assim:


$$\mathbf{x}_1 = \mathbf{x}_0 - \alpha \nabla f(\mathbf{x}_0) = \mathbf{x}_0 - \alpha \mathbf{g}$$

α ajusta o tamanho do passo e, claro, o Método do Gradiente necessita de uma estimativa inicial.

³O gradiente indica a direção de subida mais rápida de $f(\mathbf{x})$!


⁴A menor distância entre dois pontos é uma reta.

- **Exercício numérico** – buscar o mínimo de $f(x) = -2 \sin\left(x - \frac{x^2}{10}\right)$ na vizinhança de $x = 3$, considerando $\alpha = 1$:



Calcular derivadas de primeira e segunda ordem!
Número de iterações? Qual o gradiente no ponto ótimo?

- Em vez de uma aproximação linear, faz-se uma ajuste quadrático⁵ e toma um passo em direção ao mínimo/máximo:



Isso só funciona bem quando $f(\mathbf{x}) \approx$ aproximação quadrática...

⁵Há apenas uma parábola que liga três pontos x_0 , x_2 e x_3 .


- A estimativa é corrigida utilizando a equação:

$$\mathbf{x}_1 = \mathbf{x}_0 - \alpha \mathbf{H}^{-1} \mathbf{g}$$

onde $\mathbf{H}$ é a matriz **Hessiana** $\mathbb{R}^{M \times M}$:

$$\mathbf{H} = \begin{bmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial x_1^2} & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 x_2} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 x_M} \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_2 x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_2^2} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_2 x_M} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_M x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_M x_2} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_M^2} \end{bmatrix}$$

- **Exercício numérico** – buscar o mínimo de $f(x) = -2 \sin\left(x - \frac{x^2}{10}\right)$ na vizinhança de $x = 3$, considerando $\alpha = 1$:



Número de iterações?

- Autores: Charles George **Broyden**, Roger **Fletcher**, Donald **Goldfarb** and David **Shanno**;
- Pertence à classe de métodos **quase-Newton** e é uma generalização do Método da Secante;
- O BFGS evita o cálculo da Hessiana **H** – faz-se uma aproximação **B** utilizando via termos de primeira ordem;

$$\mathbf{B}_1 = \mathbf{B}_0 + \frac{\mathbf{y}\mathbf{y}^T}{\mathbf{y}^T\mathbf{s}} - \frac{\mathbf{B}_0\mathbf{s}\mathbf{s}^T\mathbf{B}_0^T}{\mathbf{s}^T\mathbf{B}_0\mathbf{s}}$$

- *Post Scriptum*: já existe um cálculo **direto** de $\mathbf{B}^{-1} \triangleq \mathbf{D}$:

$$\mathbf{D}_1 = \mathbf{D}_0 + \frac{(\mathbf{s}^T\mathbf{y} + \mathbf{y}^T\mathbf{D}_0\mathbf{y})(\mathbf{s}\mathbf{s}^T)}{(\mathbf{s}^T\mathbf{y})^2} - \frac{\mathbf{D}_0\mathbf{y}\mathbf{s}^T + \mathbf{s}\mathbf{y}^T\mathbf{D}_0}{\mathbf{s}^T\mathbf{y}}$$

- Inicializa-se **B**₀ ou **D**₀ com qualquer matriz definida positiva, exemplo: **I** com dimensões $M \times M$.

Algoritmo, considerando sempre $\alpha = 1$ e inicializando $\mathbf{B}_0$ ou $\mathbf{D}_0$ como no *slide* anterior:

- 1 Calcula a direção $\mathbf{s} = -\alpha \mathbf{B}^{-1} \mathbf{g}_0$ ou $\mathbf{s} = -\alpha \mathbf{D} \mathbf{g}_0$;
- 2 Calcula a nova estimativa $\mathbf{x}_1 = \mathbf{x}_0 + \mathbf{s}$;
- 3 Avalia o gradiente no ponto $\mathbf{x}_1 \rightarrow \mathbf{g}_1 = \nabla f(\mathbf{x}_1)$;
- 4 $\mathbf{y} = \mathbf{g}_1 - \mathbf{g}_0$;
- 5 Calcula $\mathbf{B}_1$ ou $\mathbf{B}_0$.



- Todos os exemplos foram dados em torno de funções escalares, mas $\mathbf{x} = \begin{bmatrix} x_1 & x_2 & \cdots & x_M \end{bmatrix}^T$;
- De maneira genérica, como saber se o ponto é um máximo ou mínimo?
 - 1 A Hessiana é definida-positiva, ou seja, todos os seus autovalores são **positivos** no ponto ótimo $\mathbf{x}_0$? Então $\mathbf{x}_0$ é um mínimo;
 - 2 Hessiana definida-negativa? Então $\mathbf{x}_0$ é um máximo;
 - 3 A Hessiana possui autovalores positivos e negativos? **Ponto de sela** (próximo *slide*).
 - 4 Nenhum desses casos? **Inconclusivo**.



Resumo

Pontos críticos

Aula 07

Hugo Silva

Introdução





Razão Áurea

Gradiente

Método de
Newton

BFGS

Resumo



Ver arquivos das figuras!

Gradiente, Newton e BFGS podem sofrer de **otimização insuficiente**:




Figure 3.2 Insufficient reduction in f .

Para isso existe α nas fórmulas de atualização da estimativa!

- Gradiente, Newton e BFGS → métodos iterativos de *line search*;
- Buscam um ponto estacionário → $\mathbf{g} = \mathbf{0}$;
- Por que Newton e não Gradiente?
 - 1 Gradiente tem taxa de convergência **linear**. No Newton é **quadrática** → passos mais diretos;
 - 2 Gradiente pode fazer zig-zags → muito ineficiente;
 - 3 Gradiente dá passos largos no início, depois fica **muito** lento.
- Por que BFGS e não Newton?
 - 1 **H** precisa ser definida positiva⁶, senão o Newton não toma um caminho descendente. **B** ou **D** sempre são;
 - 2 Imagine calcular **H** para $f(\mathbf{x})$ com 10.000 variáveis? Agora imagine invertê-la...
 - 3 Menor esforço computacional, mesmo quando há mais iterações.

⁶E isso nem sempre acontece!

- Não há *one size fits all*!
- **Gradiente-conjugado** é uma alteração que leva em consideração os gradientes anteriores;
- Método de Newton Modificado ajusta α de acordo com as **Condições de Wolfe** (Nocedal, Wright - Numerical Optimization pp. 33);
- Métodos quase-Newton: **BFGS**, Davidon-Fletcher-Powell (DFP), *Symmetric Rank-One Update* (SR1);
- Métodos ***trust region*** tentam resolver as fraquezas do Método de Newton quando **H** não é definida positiva ou a função é altamente não-linear;
- Ainda há métodos **heurísticos**. Um exemplo é o **Nelder-Mead**;
- Ver Auxiliar-Stanford-AA222-Lecture3.pdf pp. 35–38 e gifs do Nelder-Mead.

Aula 07

Hugo Silva

Introdução

Razão Áurea

Gradiente

Método de
Newton

BFGS

Resumo

Lista 4: Método do Gradiente (*Steepest Descent*)/Método de Newton/BFGS para equações multidimensionais.