

Aula 08 - Ajuste de Curvas

Hugo Vinícius Leão e Silva

hugovlsilva@gmail.com, hugo.vinicius.16@gmail.com, hugovinicius@ifg.edu.br

Instituto Federal de Educação, Ciência e Tecnologia de Goiás
Campus Anápolis
Curso de Bacharelado em Ciência da Computação

16 de setembro de 2021



Aula 08

Hugo Silva

Introdução

Least Squares


Interpolação

1 Introdução

2 Least Squares

3 Interpolação

O que é ajuste de curvas? A partir dos dados amostrados, preencher com estimativas intermediárias.




Quem foi melhor? Em outras palavras, qual ajuste mais se encaixou à amostra?

(a) Mínimos Quadrados (Least Squares), (b) Interpolação Linear, (c) Interpolação Curvilínea?

Uma aplicação prática: zoom digital!

- Quando a amostra em si possui erro ou **ruído** significativo, não faz muito sentido em ajustar a curva exatamente. Faz-se a **Regressão por Mínimos Quadrados**;
- Por outro lado, quando a amostra é precisa, utiliza-se **interpolação**.




- O ajuste mais simples para mínimos quadrados é a **regressão linear**:

$$y = a_0 + a_1x + e$$


$$e = y - a_0 - a_1x$$

onde y é o ajuste, a_0 a intersecção com o eixo y , a_1 a inclinação da reta e e é o erro (ou o resíduo) entre o modelo e a amostra.

Mas o que é resíduo? Vejamos um *fit* com resíduo pequeno e grande



(a)



(b)



Least Squares

Ajuste Linear

Aula 08

Hugo Silva

Introdução

Least Squares

Interpolação

- Como diminuir esse resíduo? Ou seja, como fazer um reta que “melhor” se ajuste aos dados? Minimizar a somatória dos resíduos?

$$\sum_{i=1}^n e_i = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)$$


- Minimizar o resíduo absoluto?

$$\sum_{i=1}^n |e_i| = \sum_{i=1}^n |y_i - a_0 - a_1 x_i|$$


- Minimizar a distância do ponto mais distante da reta?

Resposta: nenhum deles é bom, por quê?


- Ao minimizar a soma do resíduo, o erro pode ser *negativo*, qualquer reta que passe pelo ponto médio minimizaria o resíduo (a);
- Ao minimizar o resíduo absoluto também não produz um bom encaixe (b);
- Ao minimizar a distância máxima, um *outlier* pode produzir a situação ilustrada em (c).



(a)



(b)



(c)

- A solução é minimizar a diferença quadrática:

$$\begin{aligned}\sum_{i=1}^n e_i^2 &= \sum_{i=1}^n (y_{i,\text{medido}} - y_{i,\text{modelo}})^2 \\ &= \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2\end{aligned}$$

- Uma única reta serve para toda a amostra. O ideal é fazer a diferença quadrática ser nula, então:

$$a_1 = \frac{n \sum_{i=1}^n (x_i y_i) - \sum_{i=1}^n (x_i) \sum_{i=1}^n (y_i)}{n \sum_{i=1}^n (x_i^2) - (\sum_{i=1}^n x_i)^2}$$

e

$$a_0 = \bar{y} - a_1 \bar{x}$$

onde n é o número de amostras e $\bar{x}$ e $\bar{y}$ são as médias aritméticas de x e y , respectivamente.



Least Squares

Ajuste Linear

Aula 08

Hugo Silva

Introdução

Least Squares

Interpolação

- Certo, mas como saber se o ajuste foi bom? Respostas:
Coeficientes de determinação r^2 e de correlação r :

$$r^2 = \frac{S_t - S_r}{S_t}$$

$$r = \sqrt{r^2}$$

onde $S_r = \sum_{i=1}^n [\mathbf{y}_i - (a_0 + a_1 \mathbf{x}_i)]^2$ e $S_t = \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}})^2$.







Exercício numérico 1: Implementar o *Linear Least Squares* e avaliar r^2 e r para:

1 $\mathbf{x} = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 & 6 & 7 \end{bmatrix}$ e
 $\mathbf{y} = \begin{bmatrix} 0,5 & 2,5 & 2 & 4 & 3,5 & 6 & 5,5 \end{bmatrix};$

2 $\mathbf{x} = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 & 6 & 7 \end{bmatrix}$ e $\mathbf{y} = 2\mathbf{x};$

3 $\mathbf{x} = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 & 6 & 7 \end{bmatrix}$ e $\mathbf{y} = \mathbf{x}^2.$

- Quanto mais não-lineares são os dados, pior é o *fitness*, pois assume-se relação linear entre **x** e **y**: $y = a_1x + a_0$, o que nem sempre é verdade;
- Entretanto, há a linearização relações não-lineares:



- Para linearizar uma equação, fazem-se manipulações algébricas, ex. para o modelo exponencial:

$$y = \alpha_1 e^{\beta_1 x}$$

$$\ln(y) = \ln(\alpha_1) \ln(e^{\beta_1 x})$$

$$\ln(y) = \ln(\alpha_1) \beta_1 x$$

- Modelo de potência simples:

$$\log(y) = \beta_2 \log(x) + \log(\alpha_2)$$

- Modelo da taxa de crescimento da saturação:

$$\frac{1}{y} = \frac{\beta_3}{\alpha_3} \frac{1}{x} + \frac{1}{\alpha_3}$$



Least Squares

Ajuste Polinomial

Aula 08

Hugo Silva

Introdução

Least Squares

Interpolação

- Entretanto, nem sempre uma reta se ajusta bem à amostra;
- É possível generalizar o *Least Squares* para o caso polinomial de ordem M ;
- Para isso, deve-se calcular a equação do resíduo e derivá-la parcialmente em relação aos $(M + 1)$ coeficientes $a_0, \dots, a_M$ e solucionar o sistema de equações normais;
- De forma geral, o que se deve fazer é:
 - 1 Informar a ordem M do polinômio a ser utilizado no ajuste;
 - 2 Adicionar os n dados. Se $n < M + 1$, o ajuste é impossível;
 - 3 Montar a matriz aumentada $(M + 1) \times (M + 2)$ do sistema das equações normais;
 - 4 Solucionar o sistema, obtendo $a_0, \dots, a_M$;
 - 5 Imprimir o resultado.

- Ao solucionar o sistema linear (cujo algoritmo está no livro), você obtém $\mathbf{a}$;
- A definição do vetor de coeficientes é
 $\mathbf{a} = [a_0 \ a_1 \ \cdots \ a_M]$, exemplo:
 $\mathbf{a} = [2 \ 3 \ 4 \ 5]$ é relativo a $f(x) = 2 + 3x + 4x^2 + 5x^3$.
- Como calcular $f(x)$ para $x = 3$?

Outro problema: como calcular r^2 ?

$$r^2 = \frac{S_t - S_r}{S_t}$$

$$r = \sqrt{r^2}$$

onde $S_r = \sum_{i=1}^n [\mathbf{y}_i - f(\mathbf{x}_i)]^2$ e $S_t = \sum_{i=1}^n (\mathbf{y}_i - \bar{\mathbf{y}})^2$.

Exercício numérico 2: executar o *fit*/ajuste sobre os dados abaixo utilizando polinômios de grau 1 a 6.

$$\mathbf{1} \quad \mathbf{x} = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 & 6 & 7 \end{bmatrix} \text{ e} \\ \mathbf{y} = \begin{bmatrix} 0,5 & 2,5 & 2 & 4 & 3,5 & 6 & 5,5 \end{bmatrix};$$

$$\mathbf{2} \quad \mathbf{x} = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 & 6 & 7 \end{bmatrix} \text{ e } \mathbf{y} = 2\mathbf{x};$$

$$\mathbf{3} \quad \mathbf{x} = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 & 6 & 7 \end{bmatrix} \text{ e } \mathbf{y} = \mathbf{x}^2.$$



Least Squares

Observações finais

Aula 08

Hugo Silva

Introdução

Least Squares

Interpolação

- Embora tratamos apenas o caso unidimensional, pode ser estendido para o caso multidimensional.
- Além disso, há casos que nem o ajuste linear nem o ajuste polinomial podem ser bons, como em:

$$f(x) = a_0(1 - e^{-a_1x}) + e$$


- Neste caso, deve-se fazer um ajuste não-linear utilizando os métodos de Gauss-Newton ou Levenberg-Marquardt;
- No primeiro, utiliza-se a expansão em Série de Taylor para aproximar a equação não-linear original e aplica a teoria dos mínimos quadrados para realizar uma *minimizar* o resíduo/erro;
- Ambos são métodos iterativos e se assemelham ao Método de Newton;
- E a **extrapolação**? O que é? Vamos fazer o n.º 1 do do slide anterior no Excel.

- Outra técnica para preencher o espaço entre dados amostrais é a **interpolação**;
- Uma aplicação prática da interpolação é o **zoom digital** em câmeras e computadores;
 - Vamos no Paint.NET fazer um exemplo de interpolação!

- O primeiro que veremos é o **interpolador linear**:

$$f_1(x) = f(x_0) + \frac{f(x_1) - f(x_0)}{x_1 - x_0}(x - x_0)$$

- É o mais simples, apenas liga-se os pontos x_0 e x_1 usando uma reta:




Exercício numérico 3: vamos supor que a matriz abaixo represente uma imagem em escala-de-cinza. O valor é a intensidade do brilho:

35	40	100	30
15	15	10	20
10	80	80	0
20	90	10	15

Vamos aplicar o interpolador linear:

35		40		100		30	
15		15		10		20	
10		80		80		0	
20		90		10		15	

Exercício numérico 4: agora vamos aplicar a interpolação a $f(x) = \log_e(x)$ em $x = 2$ considerando a) entre $x_0 = 1$ e $x_1 = 6$ e b) entre $x_0 = 1$ e $x_1 = 4$.



Outro interpolador é o **quadrático**. Ele utiliza três pontos:

$$f_2(x) = a_0 + a_1x + a_2x^2$$

onde:

$$a_0 = b_0 - b_1x_0 + b_2x_0x_1$$

$$a_1 = b_1 - b_2x_0 - b_2x_1$$

$$a_2 = b_2$$

$$b_0 = f(x_0)$$

$$b_1 = \frac{f(x_1) - f(x_0)}{x_1 - x_0}$$

$$b_2 = \frac{\frac{f(x_2) - f(x_1)}{x_2 - x_1} - \frac{f(x_1) - f(x_0)}{x_1 - x_0}}{x_2 - x_0}$$



Interpolação

Interpoladores de Newton e de Lagrange

Aula 08

Hugo Silva





Introdução

Least Squares

Interpolação

- A mecânica da interpolação mostrada até agora pode ser generalizada utilizando polinômios interpoladores de Newton;
- Polinômios interpoladores de Lagrange uma reformulação dos de Newton e a programação é mais simples;
- Em todo caso, os polinômios possuem ordem $N - 1$, calculados a partir das N amostras de dados;
- Esse polinômio de ordem $N - 1$ passa exatamente pelos N pontos.

- Outra alternativa é utilizar um polinômio de ordem mais baixa do que $N - 1$, chamada funções *splines*, gerando menos oscilações;
- Em Newton e Lagrange, aumenta-se o n.º de amostras e o de oscilações. A última figura é a interpolação de uma *spline* linear.



- *Splines* lineares ligam dois pontos utilizando uma reta;
- As $N - 1$ retas que ligam os N pontos são:

$$f(x) = f(x_0) + m_0(x - x_0), x_0 \leq x \leq x_1$$

$$f(x) = f(x_1) + m_1(x - x_1), x_1 \leq x \leq x_2$$

$$\vdots$$

$$f(x) = f(x_{(N-1)}) + m_{(N-1)}(x - x_{(N-1)}), x_{(N-1)} \leq x \leq x_N$$

onde m_i é a inclinação da reta que liga os pontos:

$$m_i = \frac{f(x_{(i+1)}) - f(x_i)}{x_{(i+1)} - x_i}$$



Interpolação

Interpolação por *splines*

Aula 08

Hugo Silva

Introdução




Least Squares

Interpolação

Exercício numérico 5: Interpolar utilizando *splines* lineares considerando $x = 5$ e os dados abaixo:

x	$f(x)$
3,0	2,5
4,5	1,0
7,0	2,5
9,0	0,5

- Para garantir M -ésimas derivadas sejam contínuas deve-se utilizar *splines* de ordem $M + 1$;



- Criam-se polinômios de ordem $M + 1$ entre todos os intervalos com as seguintes restrições:
 - Valores da função e dos polinômios adjacentes devem ser iguais nos nós interiores;
 - A primeira e última *splines* devem passar pelos nós extremos;
 - Derivadas de ordem $1, 2, \dots, (M - 1)$ nos nós interiores devem iguais;
 - Derivada segunda é nula no primeiro nó.
- As *splines* mais utilizadas na prática são quadráticas e cúbicas.



Interpolação

Interpolação por *splines*

Aula 08

Hugo Silva

Introdução

Least Squares

Interpolação

- Para isso, deve-se montar um sistemas de equações lineares;
- Ao solucionar o sistema, obtém-se os coeficientes de todos os polinômios;
- Para *splines* quadráticas, determina-se a , b e c em $f(x) = ax^2 + bx + c$



Aula 08

Hugo Silva

Introdução

Least Squares

Interpolação

Lista 5a: *Least Squares* Polinomiais e Interpolador de Lagrange.
Lista 5b: Trabalho sobre interpolação.